

Rapport d'Initiation à la Recherche

Clarence Auerbach

Résumé

Ce rapport présente une étude de l'article "*Linearly-solvable Markov Decision Problems*" publié en 2006 par Emanuel Todorov [1]. Nous introduisons d'abord le cadre théorique des processus de décision markoviens (MDP), puis nous détaillons la contribution principale de l'article, à savoir une reformulation linéaire du problème de contrôle optimal. Enfin, nous présentons l'utilisation pratiques des ces MDP, les algorithmes associés et discutons leurs implications.

1 Introduction

Les processus de décision markoviens (MDP) constituent un cadre fondamental pour modéliser la prise de décision séquentielle en environnement incertain. Ils sont au cœur du domaine du *reinforcement learning*, largement développé dans l'ouvrage de Sutton et Barto [2].

L'article de Todorov (2006) propose une approche novatrice permettant de transformer certains MDP en problèmes linéaires, simplifiant considérablement leur résolution. Ce travail s'inscrit dans la continuité des recherches visant à améliorer l'efficacité computationnelle des méthodes de contrôle optimal.

2 Présentation théorique

2.1 Processus de décision markoviens

Un MDP est défini par :

- un ensemble d'états S
- un ensemble d'actions $i \in S, U(i)$
- une fonction de transition $\mathbb{P}(i'|i, u)$
- une fonction de coût $l(i, u)$

Le MDP d'un problème donné peut être vu comme "l'environnement", dans lequel se trouve notre "agent", qui doit atteindre un état terminal ou absorbant. Jusqu'à maintenant les MDPs définissent leur espace d'actions possibles en un état $i \in S$ par un ensemble finis $U(i)$.




FIGURE 1 – On commence en un état i , on choisit une action a ou a' possible à partir de cet état, cette action impacte les probabilités de transition vers j . Le coût est en fonction de i et a .

Le but est de trouver la suite d'action à prendre à partir de n'importe quel état qui minimise l'espérance du coût total pour l'agent pour atteindre un état absorbant. En effet pour une suite d'action définie, la trajectoire et donc le coût peuvent varier.

Dans la suite, S désigne un ensemble fini d'états, $\forall i \in S$, $U(i)$ un ensemble continue d'actions possible depuis i . On note $\forall u \in U(i)$, $P(u)$ est la matrice stochastique $n \times n$, $n = |S|$ de transition $i \rightarrow_u j$, contenant les éléments $p_{ij}(u) = \mathbb{P}(j|i, u)$. On note $l(i, u) \geq 0$ le coût de l'étape $i \rightarrow_u j$.

Enfin $A \subseteq S$, $A \neq \emptyset$ est l'ensemble des états absorbants, non vide, tel que $\forall i \in A$, $\forall u \in U(i)$, $p_{ij}(u) = \delta_i^j$, et $l(i, u) = 0$.

Lorsque A est atteignable en un nombre fini d'étapes avec une probabilité non nulle l'équation de Bellman admet une unique solution [3] :

$$v(i) = \min_{u \in U(i)} \left[l(i, u) + \sum_{j \in S} p_{ij}(u) v(j) \right] \quad (1)$$

L'équation récursive est la formulation mathématique de notre problème d'optimisation, qui est de minimiser l'espérance du coût. La fonction valeur $v(i)$ est donc l'espérance depuis i . On démontre l'existence et l'unicité d'une valeur minimum.

Existence et unicité de la fonction valeur

Cadre. On note S l'espace d'états fini, $A \in S$ l'état absorbant avec $l(A, u) = 0$ pour tout u , et on pose $S' = S \setminus \{A\}$. On travaille dans l'espace de Banach (ev complet normé)

$$\mathcal{V} = \{v : S \rightarrow \mathbb{R} \mid v(A) = 0\}, \quad \|v\| = \max_{i \in S'} |v(i)|.$$

On définit l'opérateur de Bellman $T : \mathcal{V} \rightarrow \mathcal{V}$ par

$$(Tv)(i) = \min_{u \in U(i)} \left[l(i, u) + \sum_{j \in S} p_{ij}(u) v(j) \right], \quad i \in S', \quad (Tv)(A) = 0.$$

L'équation (1) s'écrit alors $v = Tv$, i.e. v est un point fixe de T .

Hypothèse. L'état A est atteignable en un nombre fini d'étapes avec probabilité non nulle : il existe $N \in \mathbb{N}^*$ et $\alpha \in (0, 1]$ tels que, pour tout état initial $i \in S'$ et toute politique admissible π ,

$$\mathbb{P}^\pi(\exists k \leq N, X_k = A \mid X_0 = i) \geq \alpha$$

ou

$$\mathbb{P}^\pi(\forall k \geq N, X_k \neq A \mid X_0 = i) \leq 1 - \alpha$$

Théorème 1. *Sous l'hypothèse ci-dessus, l'équation de Bellman $v = Tv$ admet une unique solution dans $\mathcal{V}$.*

Démonstration. On procède en deux étapes.

T est non-expansif (1-Lipschitz). Pour tous $v, w \in \mathcal{V}$ et tout $i \in S'$, on a

$$\begin{aligned} |(Tv)(i) - (Tw)(i)| &\leq \max_{u \in U(i)} \left| \sum_{j \in S} p_{ij}(u) (v(j) - w(j)) \right| \\ &\leq \max_{u \in U(i)} \sum_{j \in S} p_{ij}(u) |v(j) - w(j)| \\ &\leq \|v - w\|, \end{aligned}$$

où l'on a utilisé $\sum_j p_{ij}(u) = 1$ et $v(A) = w(A) = 0$. Donc $\|Tv - Tw\| \leq \|v - w\|$.

Théorème 2. (Bertsekas) *Sous l'hypothèse, il existe une fonction $\rho : S' \rightarrow [1, +\infty)$ et une constante $\lambda \in (0, 1)$ telles que, pour tout $i \in S'$,*

$$\min_{u \in U(i)} \sum_{j \in S'} p_{ij}(u) \rho(j) \leq \lambda \rho(i).$$

Pour la norme pondérée $\|v\|_\rho = \max_{i \in S'} |v(i)|/\rho(i)$, l'opérateur T est une contraction de rapport λ sur $(\mathcal{V}, \|\cdot\|_\rho)$.

Démonstration. cf. Dimitri P. Bertsekas Dynamic Programming Chap. 2 [7] □

2.2 Construction des MDPs de Todorov

On pose $\mathbf{u} \in \mathbb{R}^{|S|}$ notre vecteur réel d'actions, u_j est un réel qui doit modifier la probabilité d'arriver dans l'état j , sinon la transition n'est pas "contrôlée", il n'y aurait aucun choix d'actions à faire. Étant donné une matrice de transition non-contrôlée $\bar{P}$ contenant $\bar{p}_{i,j}$ ou définit les probabilités de transitions :

$$p_{i,j}(\mathbf{u}) = \bar{p}_{i,j} \exp(u_j) \quad (2)$$

On remarque que $P(0) = \bar{P}$ ($p_{i,j}$ est continue positive), et plus généralement, l'idée de "contrôle" vient de la dilatation ou contraction de la probabilité que permet l'action. La définition (2) apporte deux contraintes implicites. Premièrement $\bar{p}_{i,j} = 0 \implies p_{i,j}(\mathbf{u}) = 0$, dans ce cas on prendra $u_j = 0$ même si il n'a pas d'effet. Deuxièmement $P(u)$ doit être stochastique (la somme de chaque ligne vaut 1). Les actions possibles sont :

$$U(i) = \{\mathbf{u} \in \mathbb{R}^{|S|} : \sum_{j \in S} \bar{p}_{i,j} \exp(u_j) = 1 : \bar{p}_{i,j} = 0 \implies u_j = 0\} \quad (3)$$

Les actions, étant des vecteurs réels, permettent de définir naturellement un coût pour une certaine action. On regarde la "différence" entre la répartition de probabilité non-contrôlée et la répartition contrôlée.

2.2.1 Divergence de Kullback-Leibler

Soient P et Q deux distributions de probabilité sur un espace finis ou dénombrable. La *divergence de Kullback-Leibler* de P par rapport à Q est définie par

$$D_{\text{KL}}(P \parallel Q) = \sum_{x \in \mathcal{X}} P(x) \log \frac{P(x)}{Q(x)},$$

avec la convention $0 \log \frac{0}{q} = 0$ et $p \log \frac{p}{0} = +\infty$ si $p > 0$.

2.2.2 Propriétés fondamentales

Proposition (Non-négativité — inégalité de Gibbs). *Pour toutes distributions P, Q ,*

$$D_{\text{KL}}(P \parallel Q) \geq 0,$$

avec égalité si et seulement si $P = Q$ presque partout.

Démonstration. On applique l'inégalité de Jensen à la fonction convexe $\varphi(t) = -\log t$:

$$D_{\text{KL}}(P \parallel Q) = \mathbb{E}_P \left[-\log \frac{dQ}{dP} \right] \geq -\log \mathbb{E}_P \left[\frac{dQ}{dP} \right] = -\log 1 = 0.$$

L'égalité dans Jensen pour une fonction strictement convexe a lieu si et seulement si $\frac{dQ}{dP}$ est P -p.s. constante, ce qui donne $P = Q$. $\square$

Proposition. *En général, $D_{\text{KL}}(P \parallel Q) \neq D_{\text{KL}}(Q \parallel P)$. La divergence KL n'est donc pas une distance au sens métrique.*

2.2.3 Lien avec l'entropie

On rappelle que l'*entropie de Shannon* de P est

$$H(P) = -\sum_x P(x) \log P(x) = -\mathbb{E}_P[\log P],$$

et l'*entropie croisée* de P par rapport à Q est

$$H(P, Q) = -\mathbb{E}_P[\log Q].$$

On a alors la décomposition fondamentale

$$\boxed{D_{\text{KL}}(P \parallel Q) = H(P, Q) - H(P),}$$

qui s'interprète comme le *surcoût d'information* engendré par l'utilisation de Q comme modèle à la place de la vraie distribution P .

2.2.4 Interprétation

Par le théorème de codage de Shannon, $H(P)$ est le nombre minimal de bits nécessaires pour encoder un symbole distribué selon P . Si l'on utilise à la place un code optimal pour Q , le coût moyen devient $H(P, Q)$, et l'excès est exactement $D_{\text{KL}}(P \parallel Q) \geq 0$.

2.2.5 Retour au problème

On applique donc la KL-divergence[4] à notre distribution non-contrôlée et contrôlée, qui résulte en cette définition. Soit $\mathbf{p}_i(\mathbf{u})$ la i -ème ligne de la matrice $P(\mathbf{u})$, c'est-à-dire les probabilités contrôlées de toutes les transitions partant de i , on définit le coût de l'action :

$$r(i, \mathbf{u}) := KL(\mathbf{p}_i(\mathbf{u}) \parallel \mathbf{p}_i(0)) = \sum_{j \in S, \bar{p}_{i,j} \neq 0} p_{i,j}(\mathbf{u}) \log \left(\frac{p_{i,j}(\mathbf{u})}{p_{i,j}(0)} \right) \quad (4)$$

De la divergence KL on obtient $r(i, \mathbf{u}) \geq 0$, et $r(i, \mathbf{u}) = 0 \iff \mathbf{u} = 0$. En substituant 2 et 4, et simplifiant, le coût de l'action $\mathbf{u}$ devient :

$$r(i, \mathbf{u}) = \sum_{j \in S} p_{i,j}(\mathbf{u}) u_j \quad (5)$$

Une interprétation de ce résultat est que le coût de notre action est la moyenne pondérée par les probabilités de transitions de notre action elle-même. Donc une action qui s'éloigne beaucoup de 0, c'est-à-dire $P(\mathbf{u})$ s'éloigne de $\bar{P}$, a un plus grand coût. De plus, cette moyenne est l'espérance, ou le coût attendu avant d'effectuer la transition, si lorsque que l'on effectue vraiment la transition vers j , on paye u_j . On ne peut pas choisir nos $u_j \ll 0$ car $\mathbf{u}$ doit suivre les contraintes 3.

En revenant à la construction de nos MDP, on autorise un coût d'état $q(i) \geq 0$ (i.e un coût "d'être dans l'état"), qui s'ajoute au coût d'action ci-dessus, on définit le coût total :

$$l(i, \mathbf{u}) := q(i) + r(i, \mathbf{u}) \quad (6)$$

On demande que $q(i) = 0$ pour les états absorbants $i \in A$ pour que le processus puisse continuer indéfiniment sans induire plus de coûts. En substituant 5,6 dans 1, l'équation de Bellman devient :

$$v(i) = \min_{u \in U(i)} \left[q(i) + \sum_{j \in S} \bar{p}_{ij}(u) \exp(u_j) (u_j + v(j)) \right] \quad (7)$$

2.3 Résolution du problème d'optimisation sous contraintes

Nous pouvons à présent exploiter les fruits de cette construction inhabituelle. La minimisation dans 7 sous les contraintes 3 peut produire une expression sous forme fermée (ou forme explicite), en utilisant le multiplicateur de Lagrange comme suit. On définit le Lagrangien pour chaque $i \in S$:

$$\mathcal{L}(\mathbf{u}, \lambda_i) = \sum_{j \in S} \bar{p}_{ij}(u) \exp(u_j) (u_j + v(j)) + \lambda_i \left(\sum_{j \in S} \bar{p}_{ij} \exp(u_j) - 1 \right) \quad (8)$$

Les conditions nécessaires pour un extremum selon u_j sont

$$0 = \frac{\partial \mathcal{L}}{\partial u_j} = \bar{p}_{ij}(u) \exp(u_j) (u_j + v(j) + \lambda_i + 1) \quad (9)$$

Lorsque $\bar{p}_{ij} \neq 0$ la seule solution est

$$u_j^* = -v(j) - \lambda_i - 1 \quad (10)$$

On peut vérifier que le résultat est bien un minimum. Dériver une seconde fois en $u_j^*(i)$ donne

$$\frac{\partial \mathcal{L}}{\partial u_j \partial u_j}(u_j^*(i)) = \bar{p}_{ij} \exp(u_j^*(i)) > 0 \quad (11)$$

D'où 11 est un minimum. Le multiplicateur de Lagrange peut être calculé en appliquant la contrainte 3.

La contrainte de normalisation $\sum_{j \in S} u^*(j | i) = 1$ donne

$$\begin{aligned}
& \sum_{j \in S} \bar{p}_{ij} e^{-v(j) - \lambda_i - 1} = 1 \\
& \iff e^{-\lambda_i - 1} \sum_{j \in S} \bar{p}_{ij} e^{-v(j)} = 1 \\
& \iff -\lambda_i - 1 + \log \left(\sum_{j \in S} \bar{p}_{ij} e^{-v(j)} \right) = 0 \\
& \iff \log \left(\sum_{j \in S} \bar{p}_{ij} e^{-v(j)} \right) - 1 = \lambda_i,
\end{aligned} \tag{12}$$

on a utilisé que $\log$ est une bijection strictement croissante, et que $\sum_j \bar{p}_{ij} e^{-v(j)} > 0$.

Donc la loi de contrôle optimal est

$$u_j^*(i) = -v(j) - \log \left(\sum_{k \in S} \bar{p}_{i,k} \exp(-v(k)) \right) \tag{13}$$

On a donc exprimé la loi de contrôle optimal sous une forme fermée étant donnée la fonction de valeurs optimales. Dans cette expression l'état initial i n'a pas un grand impact sur $u_j^*(i)$ étant donné qu'il n'apparaît que dans le logarithme. Cela indique que le contrôleur, ou la loi de contrôle optimal, dirige l'agent sur la bonne trajectoire sans être précis sur quels états choisir à chaque étape. Les détails de la trajectoire émergent de l'interaction du contrôleur et des dynamiques stochastiques non-contrôlées. En particulier, en substituant et simplifiant 13 dans 2 les transitions de probabilités correspondant à la loi de contrôle optimal sont

$$\begin{aligned}
p_{ij}(u^*(i)) &= \bar{p}_{i,j} \exp \left(-v(j) - \log \left(\sum_{k \in S} \bar{p}_{i,k} \exp(-v(k)) \right) \right) \\
&= \frac{\bar{p}_{i,j} \exp(-v(j))}{\exp \left(\log \left(\sum_{k \in S} \bar{p}_{i,k} \exp(-v(k)) \right) \right)} \\
&= \frac{\bar{p}_{i,j} \exp(-v(j))}{\sum_{k \in S} \bar{p}_{i,k} \exp(-v(k))}
\end{aligned} \tag{14}$$

Ces probabilités sont proportionnelles au produit de deux termes : les probabilités de transitions non-contrôlées $\bar{p}_{ij}$ qui ne dépendent pas des coûts ou des valeurs, et les valeurs exponentielles des prochains états $v(j)$ qui ne dépendent pas de l'état courant. Dans le cas particulier où $\bar{p}_{ij} = \text{const}_i$ (probabilités uniformes sur les transitions) les probabilités de transitions 14 correspondent à un échantillonnage de Gibbs [5] où la fonction de valeurs optimales joue le rôle de la fonction énergie.

En substituant le contrôle optimal 13 dans l'équation de Bellman 7 et sans l'opérateur minimum,

$$\begin{aligned}
v(i) &= q(i) + \sum_{j \in S} p_{ij}(\mathbf{u}^*(i)) (u_j^*(i) + v(j)) \\
&= q(i) + \sum_{j \in S} p_{ij}(\mathbf{u}^*(i)) (-\lambda_i - 1) \\
&= q(i) - \lambda_i - 1 \\
&= q(i) - \log \left(\sum_{j \in S} \bar{p}_{i,j} \exp(-v(j)) \right)
\end{aligned} \tag{15}$$

En permutant les termes et en prenant l'exponentielle de chaque côté de 15

$$\exp(-v(i)) = \exp(-q(i)) \sum_{j \in S} \bar{p}_{i,j} \exp(-v(j)) \quad (16)$$

On pose maintenant l'application

$$z(i) = \exp(-v(i)) \quad (17)$$

Ce qui rend l'équation de Bellman minimisée linéaire

$$z(i) = \exp(-q(i)) \sum_{j \in S} \bar{p}_{i,j} z(j) \quad (18)$$

En définissant le vecteur $\mathbf{z}$ avec les composants $z(i)$, et la matrice diagonale G avec les éléments $\exp(-q(i))$ comme coefficients diagonaux, 18 devient

$$\mathbf{z} = G\bar{P}\mathbf{z} \quad (19)$$

D'où notre classe de problèmes de contrôle optimal est réduite à un problème linéaire de valeurs propres.

3 Algorithmes et méthodes appliquées

3.1 Introduction

L'intérêt principal de la classe de MDP construite dans la partie précédente est montré dans cette partie, l'efficacité de la résolution étant donné un MDP connu, et la vitesse de convergence pour l'apprentissage à partir d'échantillon.

D'une part l'équation linéaire ($O(n)$ pour une matrice sparse), permet d'obtenir la solution exacte de la fonction de valeurs optimale. On admet la conversion d'un MDP discret en MDP continu, car jusqu'à présent les algorithmes utilisés fonctionnent pour des MDP discrets, et donc tous les problèmes connus sont posés sous cette forme.

D'autre part, la majorité des problèmes d'apprentissage par renforcement ne se résolvent pas en une fonction exacte car le MDP n'est souvent pas connu, seul un échantillon de trajectoires dans l'environnement est utilisé pour trouver une approximation des valeurs optimales. On distingue donc la partie application en deux parties, les méthodes et algorithmes, pour un MDP connu (model-based ou model-known) et ceux pour un problème sans modèle connu (model-free).

3.2 Solution itérative et analyse de la convergence

D'après l'équation (19), z^* est un vecteur propre de GP associé à la valeur propre 1. De plus, $z^*(i) > 0$ pour tout $i \in S$ et $z^*(i) = 1$ pour tout $i \in A$. Existe-t-il un vecteur z vérifiant ces propriétés, et est-il unique ? La réponse aux deux questions est affirmative : l'équation de Bellman admet une unique solution, et v en est une solution si et seulement si $z = \exp(-v)$ est une solution admissible de (19). La seule question restante est donc de déterminer comment calculer cette solution unique z^* .

Méthode itérative. La méthode itérative naturelle est la suivante :

$$z_{k+1} = GP z_k, \quad z_0 = \mathbf{1}. \quad (20)$$

Cette itération converge toujours vers la solution unique, pour les raisons suivantes. Toute matrice stochastique P est de rayon spectral 1. La multiplication par G contracte certaines lignes de P , de sorte que GP est de rayon spectral au plus 1. Mais l'existence garantie d'un vecteur propre z^* associé à la valeur propre 1 implique que le rayon spectral de GP est exactement 1, et que z^* est un vecteur propre dominant. L'itération (20) est équivalente à la *méthode des puissances* (sans renormalisation, laquelle est ici superflue) et converge donc vers ce vecteur propre dominant. Les contraintes supplémentaires sur z sont satisfaites à chaque étape : en particulier, pour $i \in A$, la i -ème ligne de GP a pour éléments p_{ij} , de sorte que la i -ème composante de z_k reste égale à 1 pour tout k .

Taux de convergence. Posons $m = |A|$ et $n = |S|$. Quitte à renuméroter les états, on peut écrire GP sous la forme canonique

$$GP = \begin{pmatrix} T_1 & T_2 \\ 0 & I \end{pmatrix}, \quad (21)$$

où les états absorbants sont placés en dernier, T_1 est de taille $(n-m) \times (n-m)$, et T_2 est de taille $(n-m) \times m$. La présence de la matrice identité en bas à droite, malgré la multiplication par G , est due au fait que $q(i) = 0$ pour $i \in A$. On déduit de (21)

$$(GP)^k = \begin{pmatrix} T_1^k & (T_1^{k-1} + \dots + T_1 + I)T_2 \\ 0 & I \end{pmatrix} = \begin{pmatrix} T_1^k & (I - T_1^k)(I - T_1)^{-1}T_2 \\ 0 & I \end{pmatrix}. \quad (22)$$

Une matrice stochastique P possédant m états absorbants admet m valeurs propres égales à 1, toutes les autres étant strictement inférieures à 1 en valeur absolue. Comme les éléments diagonaux de G sont au plus 1, toutes les valeurs propres de T_1 sont strictement inférieures à 1 en module, et l'on a donc

$$\lim_{k \rightarrow \infty} T_1^k = 0.$$

L'itération (20) converge ainsi *exponentiellement*, à un taux géométrique ρ^k où $\rho < 1$ est le rayon spectral de T_1 .

Facteurs influençant la vitesse de convergence. Une valeur de ρ plus petite accélère la convergence. Deux facteurs contribuent à réduire ρ :

1. des coûts d'état $q(i)$ élevés, qui diminuent les termes $e^{-q(i)}$ sur la diagonale de G ;
2. de faibles probabilités de transition entre états non absorbants (et, corrélativement, de fortes probabilités de transition vers les états absorbants).

La vitesse de convergence est *indépendante de la taille du problème*, car rien n'impose à ρ d'augmenter avec la dimension de T_1 . Ce comportement est confirmé par des simulations numériques sur des MDP générés aléatoirement : la taille du problème n'affecte pas systématiquement le nombre d'itérations nécessaires pour atteindre un critère de convergence donné. Le temps de calcul moyen croît donc *linéairement* avec le nombre d'éléments non nuls de P .

3.3 Implémentation

Nous implémentons l'algorithme d'itération sur un labyrinthe en grille de taille 7×7 avec des murs et un état absorbant unique A . La loi de probabilité de transition non contrôlée $\bar{p}$ est une marche aléatoire uniforme sur les voisins accessibles. Les coûts d'état sont $q(i) = 1$ pour $i \notin A$ et $q(A) = 0$.
 $A = \{(7, 7)\}$

3.4 Z-learning

Le Z-learning est l'approximation stochastique naturelle de la Z-itération lorsque le modèle de transition $\bar{p}$ n'est pas disponible. On dispose uniquement d'échantillons $(i_k, j_k, q_k)_{k \geq 0}$, où i_k est l'état courant, $j_k \sim \bar{p}(\cdot | i_k)$ est l'état suivant tiré selon la dynamique passive, et $q_k = q(i_k)$ est le coût d'état encouru.

Génération des échantillons. Les échantillons sont générés par simulation de trajectoires dans l'environnement. À chaque instant k , le système est dans un état $i_k \in S \setminus A$; on choisit une action u_k selon une politique comportementale (ici uniforme sur les voisins accessibles), et l'état suivant j_k est tiré selon la loi de transition $p(\cdot | i_k, u_k)$. On enregistre le triplet

$$(i_k, j_k, q_k), \quad q_k = q(i_k) \in \mathbb{R}_{\geq 0}.$$

Lorsque $j_k \in A$, la trajectoire est réinitialisée depuis un état non absorbant tiré aléatoirement. Contrairement au Q-learning, le Z-learning n'a pas besoin de connaître l'action u_k effectuée, c'est une méthode *off-policy*, cela revient dans notre cas à supposer que l'action est toujours 0.




FIGURE 2 – Fonction valeur $v^*(i) = -\log z^*(i)$ obtenue par Z-itération (méthode model-based). Chaque cellule affiche le coût espéré optimal depuis l'état correspondant jusqu'à l'état absorbant A (en vert). Les cellules noires sont des murs. On observe bien des valeurs décroissantes jusqu'à A , cohérentes avec la structure du labyrinthe.

Algorithme de mise à jour. L'équation aux valeurs propres (19) s'écrit

$$z^*(i) = e^{-q(i)} \mathbb{E}_{\bar{p}}[z^*(j) \mid i],$$

ce qui suggère l'approximation stochastique suivante. On maintient un estimateur $\hat{z} \in \mathbb{R}^{|S|}$ initialisé à $\hat{z} \leftarrow \mathbf{1}$, et on le met à jour à chaque échantillon (i_k, j_k, q_k) par

$$\hat{z}(i_k) \leftarrow (1 - \alpha_k) \hat{z}(i_k) + \alpha_k e^{-q_k} \hat{z}(j_k) \quad (23)$$

En pratique on utilise $\alpha_k(i) = \frac{c}{c + n_k(i)}$, où $n_k(i)$ est le nombre de visites de l'état i jusqu'à l'instant k et $c > 0$ est une constante.

Estimation de la fonction valeur. Une fois que l'algorithme a convergé, la fonction valeur optimale est récupérée par le changement de variable inverse

$$\hat{v}(i) = -\log \hat{z}(i), \quad i \in S.$$

Pour les états absorbants $i \in A$, on impose $\hat{z}(i) = 1$, ce qui donne bien $\hat{v}(i) = 0$.

Convergence. Sous les conditions de Robbins-Monro et l'hypothèse que tout état non absorbant est visité infiniment souvent, $\hat{z}$ converge presque sûrement vers z^* , l'unique solution admissible de (19).

3.5 Q-learning

Le Q-learning [6] est un algorithme d'apprentissage par renforcement model-free qui estime la fonction d'action-valeur optimale $Q^*(i, u)$, définie comme le coût espéré minimal depuis l'état i en prenant l'action u puis en suivant la politique optimale. Les échantillons sont ici des quadruplets (i_k, j_k, ℓ_k, u_k) où u_k est l'action effectuée et ℓ_k le coût de transition associé. La mise à jour est

$$\hat{Q}(i_k, u_k) \leftarrow (1 - \alpha_k) \hat{Q}(i_k, u_k) + \alpha_k \left(\ell_k + \min_{u' \in U(j_k)} \hat{Q}(j_k, u') \right), \quad (24)$$

et la fonction valeur est récupérée par $\hat{v}(i) = \min_{u \in U(i)} \hat{Q}(i, u)$.

3.6 Méthodes model-free

Lorsque le modèle de transition $\bar{p}$ n'est pas disponible, on recourt aux algorithmes d'approximation stochastique décrits à la section précédente. Les deux algorithmes reçoivent exactement les mêmes trajectoires d'échantillons (i_k, j_k, q_k) , générées par une politique comportementale uniforme sur le labyrinthe.




FIGURE 3 – Fonction valeur estimée $\hat{v}(i) = -\log \hat{z}(i)$ obtenue par Z-learning après 10^5 échantillons. La structure spatiale est fidèle à la solution model-based de la figure précédente, avec des valeurs légèrement sous-estimées près des bords du labyrinthe en raison d'une fréquence de visite plus faible.




FIGURE 4 – Fonction valeur estimée $\hat{v}(i) = -\max_u \hat{Q}(i, u)$ obtenue par Q-learning après 10^5 échantillons. Les grandes tendances sont correctement capturées, mais l'estimation est plus bruitée que celle du Z-learning, notamment dans les régions peu visitées.

La figure 5 compare la vitesse de convergence des deux algorithmes en fonction du nombre d'échantillons, mesurée par l'erreur normalisée

$$e_k = \frac{\max_{i \in S} |\hat{v}_k(i) - v^*(i)|}{\max_{i \in S} |v^*(i)|}.$$

4 Conclusion

L'approche proposée par Todorov constitue une avancée importante dans le domaine du contrôle optimal et la pertinence des MDPs avec des espaces d'actions continue.




FIGURE 5 – Erreur normalisée e_k en fonction du nombre d'échantillons pour le Z-learning (bleu) et le Q-learning (orange). Le Z-learning converge sensiblement plus vite : il atteint un niveau d'erreur donné avec environ deux fois moins d'échantillons que le Q-learning. Cet avantage s'explique par la structure log-linéaire de la mise à jour (20), qui exploite directement la forme de la solution $z^* = \exp(-v^*)$, là où le Q-learning approxime une fonction valeur sans cette information structurelle.

Des perspectives futures incluent l'application de ces méthodes à des environnements plus complexes et leur intégration dans des algorithmes d'apprentissage modernes.

Références

- [1] E.Todorov, (2006). *Linearly-solvable Markov Decision Problems*.
- [2] R.Sutton, & Barto, A. G. (2018). *Reinforcement Learning : An Introduction*.
- [3] D. Bertsekas, Athena Scientific (2000). *Dynamic programming and optimal control (2nd ed)*.
- [4] S. Kullback et R. Leibler, « On information and sufficiency », *Annals of Mathematical Statistics*, vol. 22, 1951, p. 79-86.
- [5] Geman, S. ; Geman, D. (1984). "Stochastic Relaxation, Gibbs Distributions, and the Bayesian Restoration of Images". *IEEE Transactions on Pattern Analysis and Machine Intelligence*.
- [6] Q-learning, Chris Watkins Peter Dayan, *Machine Learning*, 8, 279-292.
- [7] [Neuro-Dynamic Programming](#)